

Lecture 4.


P1. Machine Translation and the Dataset

- 机器翻译的数据集
 - 是由源语言和目标语言的文本序列对组成的
 - 下载和预处理
 - 词元化
 - 词表
 - 加载数据集
 - 训练模型

P2. The Encoder - Decoder Architecture


① For CNN

{ Encoder: Input $\rightarrow$ Features (中间表达形式)
Decoder: Features $\rightarrow$ Output
中间表示



② For RNN


{ Encoder: Text $\rightarrow$ Vector
Decoder: Vector $\rightarrow$ Output.



Models are divided into 2 parts:

Encoder: 用于表示序列 长度可变序列作为输入, 用于生成编码状态


Decoder: 有固定形状的编码映射为长度可变的序列






Let's

Sequence-to-Sequence Learning (Seq2seq)

机器翻译



编码器最后时间步隐状态 用作 解码器初始隐状态



Evaluation = BLEU (BiLingual Evaluation Understudy)

最先用于评估机器翻译的结果，现在广泛用于衡量

输出序列的质量

通过与真实的标签序列进行比较来评估预测序列

$$\exp \left(\min \left(0, 1 - \frac{\text{len}_{\text{label}}}{\text{len}_{\text{pred}}} \right) \right) \prod_{n=1}^k p_n^{1/2^n}$$

当预测序列与标签序列完全相同时，BLEU为1

D4. 束搜索

① 贪心搜索：当前时刻预测概率最大的词 可能不是最优

② 穷举搜索：对所有可能序列计算概率选最好 计算上不可行。

③ 束搜索: 每次搜索, 时保存 k 最好候选 $k=1$ 贪心 $k=n$ 穷举.