


Lecture 8 BERT

动机: 基于微调的 NLP 模型, 预训练模型抽取足够多信息, 新任务加个简单输出层.

- NLP 迁移学习:
- 使用预训练好的模型来抽取词、句子的特征
 - 例如 word2vec 或语言模型
 - 不更新预训练好的模型
 - 需要构建新的网络来抓取新任务需要的信息
 - Word2vec 忽略了时序信息, 语言模型只看了一个方向

ELMo: 为特定任务设计.
GPT: 单向架构

BERT: 把两个最好的结合起来



架构: 只有 Encoder 的 Transformer { Base
Large

输入: 每个样本是一个句子对, 加额外片段嵌入

Token 输入 Segment 输入 Position 输入
位置编码可学习

预训练 1: 带掩码语言模型. 随机将一些词元换成 <mask> 能预测不出 mask. (预测 mask)

预训练 2: 预测下一个句子 预测一个句子对中两个句子是否相邻